

Identificación automática de altiplanos en el extremo Noroccidental de los Andes colombianos mediante análisis geoespacial

Automatic identification of plateaus in the northwestern Colombian Andes through geospatial analysis

Santiago Correa Estrada¹
Edier V. Aristizábal Giraldo¹

Departamento de Geociencias y Medio Ambiente, Facultad de Minas, Universidad Nacional de Colombia, Medellín, Colombia.

sacorrae@unal.edu.co

evaristizabal@unal.edu.co

Agosto, 2026.

Abstract

Plateaus (altiplanos) are characteristic landforms of the northwestern Colombian Andes, defined by low-relief surfaces, gentle slopes, and topographic elevation relative to surrounding landscape elements. Their identification and delineation has historically relied on fieldwork and expert judgment, with limited use of geospatial data such as Digital Elevation Models (DEM). Although remote sensing and data processing have advanced considerably, the recognition of an "elevated surface" is not a clear-cut line, and drawing its boundaries poses problems of scale factor and continuous surfaces that can be classified differently at different extremes — challenges that simple map-algebra or morphometric-threshold tools cannot resolve, particularly in the central cordillera where these surfaces are not flat and smooth but hilly, incised and irregular.

This study applies a comprehensive set of geospatial statistical methods to identify and map plateaus at 50 m resolution over a 61,960 km² area in the northwestern Colombian Andes, seeking the methodology that best suits the automatic recognition of these surfaces. Using a 50 m DEM (resampled from NASA ALOS PALSAR) and derived topographic variables (slope, relative relief, altitude windows), five families of spatial models are compared: non-spatial logistic regression, hierarchical models with regional random effects, spatial autoregressive models (SAR, SEM, SDM, SAC, GNS), Bayesian Conditional Autoregressive models (ICAR, BYM, Leroux), and Gaussian Processes (GP).

Keywords: altiplanos; geospatial analysis; spatial regression; CAR models; Gaussian processes; pixel-enhancement; Colombian Andes.

Resumen

Los altiplanos son geoformas características del paisaje del norte de la Cordillera de los Andes colombianos, estos se caracterizan por presentar superficies de bajo relieve, poca pendiente y por estar topográficamente elevados frente a otros elementos del paisaje. Su identificación y delimitación hasta ahora se ha desarrollado principalmente desde el trabajo de campo y en pocas ocasiones desde el uso de datos geoespaciales como los modelos digitales de elevación (DEM). A pesar de que el uso de sensores remotos y el procesamiento de datos ha avanzado considerablemente, la identificación y delimitación de estas superficies presenta un problema difícil de resolver desde herramientas sencillas de análisis (álgebra de mapas, uso de umbrales morfométricos, etc.) dado que el reconocimiento de una superficie "elevada" no suele ser una línea clara de definir y mucho menos sus límites, presentando problemas de factor de escala y superficies continuas que pueden clasificarse de forma distinta en diferentes extremos. Frente a este tipo de obstáculos se requiere del criterio humano para dibujar la línea entre un altiplano y otro tipo de superficies y más aún en la zona central de la cordillera central, donde estas superficies no son planas y suaves, sino colinadas, incisadas e irregulares (aunque cumplan con los criterios de clasificación).

Este estudio aplica un conjunto integral de métodos estadísticos de análisis geoespaciales para identificar y cartografiar distintos altiplanos a resolución de 50 m sobre un área de 61.960 km² en el norte de los Andes colombianos, tratando de encontrar la metodología que mejor se ajuste para reconocer los altiplanos de esta región de forma automática. A partir de un Modelo Digital de Elevación de 50 m (remuestreo de ALOS PALSAR de la NASA) y variables topográficas derivadas (pendiente, relieve relativo), se comparan cinco familias de modelos espaciales: regresión logística no espacial, modelos jerárquicos con efectos aleatorios regionales, modelos autorregresivos espaciales (SAR, SEM, SDM, SAC, GNS), modelos bayesianos de Autorregresión Condicional (ICAR, BYM, Leroux) y Procesos Gaussianos (GP).

Palabras clave: altiplanos; análisis geoespacial; regresión espacial; modelos CAR; procesos gaussianos; pixel-enhancement; Andes colombianos.

1 Introducción

En la cordillera central de los Andes colombianos se presenta sobre su eje una serie de altiplanos escalonados que se concentran en su parte más septentrional. Estas superficies, conocidas como superficies de erosión o *etchplains*, son el producto de procesos geológicos complejos que involucran eventos de levantamientos tectónicos, erosión diferencial y sedimentación [1,13]. Se originan en ambientes cercanos al nivel del mar en zonas tropicales, donde la alternancia de temporadas de lluvia y períodos secos descompone los mantos de roca y la erosión genera un relieve colinado cercano al nivel base de los drenajes. Cuando estas superficies son elevadas rápidamente — normalmente en pulsos regulares — se preserva este tipo de relieve a grandes altitudes, formando sistemas escalonados de altiplanos según las tasas de meteorización/erosión y los eventos de levantamiento, siendo las superficies más altas las más antiguas [14,15].

A diferencia de otros altiplanos del territorio nacional, como los de la cordillera oriental que se originan por sedimentación continental, los altiplanos de la cordillera central presentan un paisaje colinado y de bajo relieve que es disectado por distintos sistemas de cañones y frentes de erosión, constituyendo uno de los elementos más importantes de la geomorfología en el departamento de Antioquia [13,16]. En Antioquia, la clasificación más extendida diferencia alrededor de tres niveles principales sobre el eje de la cordillera central [13,17]: el primero, más alto y antiguo, corresponde a los remanentes sobre el Páramo de Belmira, Santa Elena, el valle de la Unión y otras superficies hasta el norte de Caldas; el segundo y mejor conservado corresponde al altiplano de Santa Rosa y al Oriente antioqueño, separados por el Valle de Aburrá; y el tercero a las superficies que se extienden a cada lado del río Porce entre Gómez Plata y Yolombó y Amalfi y Anorí. Adicionalmente, se han identificado niveles intermedios sin llegar a una clasificación extendida que incluya una caracterización morfométrica y pedológica amplia o que abarque otras zonas de similar morfología como las cuencas de los ríos Bagre y Nare [13,18].

A pesar de la relevancia geomorfológica de estos altiplanos, su delimitación se ha basado principalmente en criterios topográficos y geomorfológicos que, aunque acertados, resultan subjetivos, difícilmente reproducibles y poco escalables a grandes extensiones territoriales [13,18]. La disponibilidad creciente de modelos de elevación de alta resolución y el desarrollo de técnicas de estadística espacial ofrecen una oportunidad para abordar este problema de manera cuantitativa y sistemática [3].

La estadística espacial proporciona un marco teórico robusto para modelar fenómenos que exhiben dependencia espacial, es decir, donde las observaciones cercanas tienden a ser más similares entre sí que las lejanas — un principio conocido como la Primera Ley de la Geografía de Tobler [4]. En el contexto de la clasificación de geoformas, esta dependencia se manifiesta naturalmente: un píxel clasificado como altiplano tiene alta probabilidad de estar rodeado por otros píxeles de altiplano. Ignorar esta estructura espacial,

como hacen los modelos de regresión clásicos, conduce a residuos autocorrelacionados y estimaciones subóptimas [5].

Diversos enfoques se han propuesto para incorporar la estructura espacial en modelos de clasificación: modelos autorregresivos como SAR y SEM [5], modelos bayesianos de Autorregresión Condicional (CAR) como ICAR, BYM y Leroux [6,7], modelos de heterogeneidad espacial como GWR [8], y procesos gaussianos [9]. Sin embargo, la comparación sistemática de estas familias de modelos para la clasificación de geoformas a gran escala es escasa en la literatura.

El objetivo de este estudio es identificar y cartografiar altiplanos en el noroccidente de la Cordillera de los Andes colombianos mediante técnicas de análisis geoespacial, comparando cinco familias de modelos espaciales evaluados sobre el ráster original de 50 m de resolución. Se propone además una estrategia de *pixel-enhancement* que permite transferir las predicciones de modelos areales a la resolución de detalle del DEM.

2 Datos y metodología

2.1 Área de estudio

El área de estudio comprende la zona andina del noroccidente de Colombia, cubriendo las cordilleras Central y Occidental. La zona abarca 61.960 km², con un total de 24.783.966 píxeles de 50 m de resolución. Este territorio incluye desde las zonas bajas de los valles interandinos hasta los páramos por encima de los 4.000 m de altitud, lo que genera una gran heterogeneidad topográfica que debe ser capturada por los modelos.

2.2 Variables topográficas

Todas las variables se derivaron del DEM ALOS PALSAR de la NASA, originalmente a 12,5 m de resolución y remuestreado a 50 m. Las tres variables principales son:

Altitud. Elevación sobre el nivel del mar en metros, obtenida directamente del DEM. Constituye un primer indicador de la posición topográfica de una superficie.

Pendiente. Inclinación del terreno expresada en grados, derivada del DEM a partir del gradiente de altitud entre píxeles vecinos. Es la variable que mejor distingue las superficies de bajo relieve de las laderas y cañones circundantes.

Relieve relativo. Diferencia entre la altitud máxima y la mínima dentro de una ventana circular de análisis. Captura la heterogeneidad del terreno: valores bajos indican superficies poco disectadas, mientras que valores altos señalan cañones profundos o frentes erosivos activos. Se calculó a una ventana de 10 píxeles (125 m).

Además de las tres variables principales, se construyó un conjunto de variables de contexto topográfico diseñadas para que los modelos puedan discernir la posición relativa de cada píxel frente a su entorno a distintas escalas:




Fig. 1. Altiplanos delimitados en la zona noroccidental de los Andes colombianos.

Fuente: Elaboración propia.

Ventanas de altitud máxima (Amax). Diferencia entre la altitud máxima registrada dentro de un radio determinado y la altitud propia del píxel, calculada a ventanas de 3, 10, 50, 100 y 500 píxeles (equivalentes a 150 m, 500 m, 2,5 km, 5 km y 25 km).

Ventanas de altitud mínima (Amin). De forma complementaria, esta variable mide la diferencia entre la altitud del píxel y la altitud mínima dentro del mismo radio (ventanas de 3, 10, 50 y 100 píxeles). Un valor alto indica que el píxel domina su entorno (cresta o cima), mientras que un valor cercano a cero indica una posición en el fondo del relieve local.

Diferencia de medias entre ventanas (DifMedia). Diferencia entre la altitud media calculada en una ventana pequeña y la altitud media en una ventana mayor (por ejemplo, ventanas de 10 vs. 100 píxeles, o de 3 vs. 10 píxeles). Un valor alto indica que el píxel se encuentra en una posición baja respecto a su entorno (fondo de valle o ladera), mientras que un valor cercano a cero significa que el píxel está en o cerca de la cima local. Esto permite al modelo distinguir si un píxel elevado forma parte de una superficie continua o simplemente está en la ladera de un pico, ayudando a resolver ambigüedades de escala.

Pendiente de la diferencia de medias (SlpDifMedia).

Pendiente calculada sobre las capas de diferencia de medias (ventanas de 10 vs. 50 y de 3 vs. 10 píxeles), lo que captura la tasa de cambio del contraste entre escalas y permite identificar las transiciones abruptas entre altiplanos y cañones adyacentes.

No todas las variables se utilizaron en todos los modelos: los modelos a nivel de píxel y los modelos areales emplearon las tres variables principales (altitud, pendiente y relieve), mientras que los Procesos Gaussianos, ajustados sobre una malla de 3 km con estadísticas zonales, incorporaron además las variables de contexto topográfico (8 covariables en total: Altitud, Pendiente, Relieve, Amax500, Amax100, Amin100, DifA10_100, SlpD10_50).

2.3 Delimitación manual de altiplanos de referencia

Para que los modelos puedan aprender a distinguir altiplanos del resto del terreno, es necesario contar con una capa de referencia que indique cuáles zonas corresponden a altiplano y cuáles no. Esta capa fue construida mediante digitalización manual sobre el DEM ALOS PALSAR a su resolución original de 12,5 m, un proceso que se apoyó simultáneamente en la visualización de la altitud, la pendiente y el relieve relativo calculado en una ventana de 10 píxeles (125 m de radio a dicha resolución).

El criterio general de clasificación partió de identificar superficies que mantuvieran un relieve bajo y una pendiente suave de forma continua, excluyendo las laderas pronunciadas, los cañones y los frentes erosivos que interrumpen o bordean los altiplanos [13,17]. En la práctica, esto se tradujo en delimitar como altiplano aquellas zonas donde la pendiente no superara los 16–18° y donde el relieve relativo se mantuviera por debajo de los 50 m dentro del radio de 125 m. Estos umbrales no se aplicaron de forma rígida ni automática, sino como guías dentro de un proceso que requirió criterio experto para resolver las transiciones graduales entre superficies, particularmente en los bordes donde el altiplano se funde con las laderas circundantes. Como resultado se delimitaron 491 polígonos de altiplano con un área total de aproximadamente 9.366 km², equivalente al 15,1% del área de estudio.

2.4 Zonificación regional mediante clustering

El área de estudio presenta una gran variabilidad geomorfológica: la cordillera central muestra superficies colinadas e irregulares producto de la erosión diferencial, mientras que la cordillera occidental tiene altiplanos más estrechos y dispersos. Para capturar esta heterogeneidad en los modelos, se realizó una zonificación previa mediante el algoritmo de clustering.

El procedimiento consistió en superponer una grilla regular de celdas de 5 km sobre el área de estudio (2.596 celdas). Para cada celda se calcularon los valores promedio de altitud, pendiente y relieve relativo, obteniendo así un vector de tres variables por celda. Se aplicó K-Means sobre estos vectores, evaluando de 2 a 8 clusters con el *silhouette score* para seleccionar el número óptimo de grupos. El mejor resultado se obtuvo con 4 regiones (Fig. 1): Región 1 (Cordillera Central – Valle del Magdalena), Región 2

(Cordillera Central – Altiplanos), Región 3 (Cordillera Occidental – Atrato) y Región 4 (Cordillera Occidental – Farallones). La proporción de altiplano varía sustancialmente entre regiones, desde 0,2% en R2 hasta 26,8% en R4, confirmando que las diferentes regiones tienen dinámicas geomorfológicas distintas.




Fig. 1. Área de estudio y zonificación en 4 regiones obtenidas por clustering K-Means: R1 (C. Central norte–Magdalena), R2 (C. Central sur), R3 (C. Occidental–Pacífico), R4 (Valle central–Macizo).

Fuente: Elaboración propia.

2.5 Construcción de la grilla areal y matriz de vecindad

Varios de los modelos empleados (autorregresivos y CAR) no trabajan a nivel de píxel individual sino sobre unidades areales. Para esto se utilizó la misma grilla de 5 km empleada en el clustering, resultando en 2.596 celdas. Para cada celda se calcularon los valores promedio de altitud, pendiente y relieve, así como la proporción de píxeles clasificados como altiplano. La variable respuesta se definió como binaria: 1 si más de la mitad de los píxeles de la celda corresponden a altiplano, 0 en caso contrario.

La relación de vecindad entre celdas se estableció por contigüidad tipo Rook (dos celdas son vecinas si comparten un borde, no solo un vértice), generando una matriz de pesos espaciales W que indica qué celdas son adyacentes. Esta matriz es fundamental para los modelos espaciales, ya que define cómo se transmite la influencia entre unidades vecinas.

2.6 Familias de modelos

Se compararon cinco familias de modelos, organizadas por la forma en que incorporan la estructura espacial. A continuación se describe cada una, explicando qué supuestos

hace, qué componentes agrega al modelo base y por qué se espera que mejore la clasificación de altiplanos.

a) Regresión logística no espacial (línea base). Es un modelo logístico estándar que predice la probabilidad de altiplano a partir de las covariables topográficas principales (Altiplano $\sim$ Altitud + Pendiente + Relieve), sin considerar la ubicación geográfica de cada observación. Se entrenó sobre una muestra aleatoria de 300.000 píxeles del ráster de 50 m. Este modelo asume que todos los píxeles son independientes entre sí.

b) Modelo jerárquico con efectos aleatorios regionales. Este modelo es igual al logístico base en sus efectos fijos (las mismas covariables topográficas), pero agrega un intercepto aleatorio por cada una de las 4 regiones del clustering [10]. Esto significa que cada región tiene su propio nivel base de probabilidad de altiplano, independiente de las covariables. Por ejemplo, si una región tiene en promedio más altiplanos que otra a iguales condiciones topográficas, el efecto aleatorio captura esa diferencia regional. Las covariables topográficas actúan como efectos fijos (iguales en todas las regiones) y las regiones como efectos aleatorios (varían entre grupos).

c) Modelos autorregresivos espaciales. Se ajustaron ocho modelos sobre las 2.596 celdas de 5 km usando la librería `spreg` de Python [5]. Estos modelos incorporan la dependencia espacial a través de la matriz de vecindad W , pero cada uno lo hace de forma diferente: OLS (regresión lineal sin componente espacial), SLX (agrega las variables topográficas de las celdas vecinas como covariables adicionales), SAR (agrega la variable respuesta de los vecinos, asumiendo que si los vecinos son altiplano, la celda también tiende a serlo), SEM (modela la autocorrelación directamente en los residuos del modelo), SDM (combina SAR y SLX: rezago tanto de la respuesta como de las covariables), SDEM (combina SEM y SLX), SAC (combina SAR y SEM simultáneamente) y GNS (el modelo más general, que incluye todos los componentes anteriores). Para los modelos que incorporan rezago en las covariables (SLX, SDM, SDEM, GNS), solo se rezagan las variables topográficas, no las variables indicadoras de región.

d) Modelos CAR bayesianos. Cuatro modelos ajustados sobre las mismas 2.596 celdas dentro del paradigma bayesiano [6,7]: un GLM sin efecto espacial (equivalente bayesiano de la línea base), ICAR (Intrinsic Conditional Autoregressive, que asigna a cada celda un efecto aleatorio espacial cuyo valor depende del promedio de sus vecinos), BYM (Besag-York-Mollié, que combina el efecto ICAR con un efecto aleatorio independiente por celda para capturar variabilidad no espacial) y Leroux (que pondera entre un efecto completamente espacial y uno independiente mediante un parámetro de mezcla ρ). El modelo ICAR y BYM se ajustaron con INLA (R), mientras que el Leroux se ajustó con CARBayes (R) usando cadenas MCMC de 13.000 iteraciones.

e) Procesos Gaussianos (GP). A diferencia de los modelos anteriores que trabajan sobre celdas discretas, los GP modelan la correlación espacial como una función continua de la distancia entre observaciones [9]. Se ajustó un

modelo de clasificación GP con kernel Matérn (que controla el alcance y la suavidad de la correlación espacial) y las 8 covariables topográficas descritas en la sección 2.2, incluyendo las variables de contexto (Amax, Amin, DifMedia, SlpDifMedia). Dado el alto costo computacional de los GP, se construyó una malla regular de puntos cada 3 km sobre el área de estudio, resultando en 6.902 puntos, y se submuestrearon 2.500 para el ajuste. Los datos se dividieron en entrenamiento (70%) y prueba (30%), lo que permite una evaluación independiente del desempeño.

2.7 Estrategia de pixel-enhancement

Los modelos areales (autorregresivos y CAR) producen una predicción por cada celda de 5 km, una resolución inadecuada para cartografía de detalle. Para recuperar la resolución del DEM original (50 m), se diseñó una estrategia de pixel-enhancement que combina el efecto espacial estimado por el modelo areal con las covariables topográficas a resolución de píxel. El procedimiento consta de tres pasos:

Primero, se extrae de cada modelo areal su componente espacial y se rasteriza a 50 m: en los modelos CAR se extrae el efecto aleatorio espacial ϕ (que representa la variabilidad geográfica no explicada por las covariables), mientras que en los autorregresivos se extrae la probabilidad predicha. Segundo, se entrena un nuevo modelo logístico a nivel de píxel usando como covariables las variables topográficas principales más el efecto areal rasterizado (Altiplano ~ Altitud + Pendiente + Relieve + Efecto_areal), sobre una muestra de 300.000 píxeles. Tercero, se predice sobre los 24,8 millones de píxeles válidos, obteniendo así un mapa que combina la coherencia espacial del modelo areal con el detalle topográfico local.

2.8 Métricas de evaluación

Para evaluar y comparar los modelos se utilizaron métricas complementarias. El AUC-ROC (Área Bajo la Curva ROC) mide la capacidad del modelo para distinguir entre altiplano y no-altiplano independientemente del umbral de clasificación: un valor de 1 indica clasificación perfecta. El Pseudo R^2 de McFadden indica qué proporción de la variabilidad en los datos es explicada por el modelo respecto a un modelo nulo. El AIC (Criterio de Información de Akaike) penaliza la complejidad del modelo, permitiendo comparar modelos con diferente número de parámetros. El F1-score es la media armónica entre Precision (proporción de predicciones positivas correctas) y Recall (proporción de altiplanos reales detectados), siendo especialmente relevante con datos desbalanceados como este caso donde solo el 15,1% del área es altiplano.

3 Resultados

3.1 Exploración y autocorrelación espacial

El análisis exploratorio reveló que las variables topográficas presentan distribuciones marcadamente diferentes entre las clases altiplano y no-altiplano: los altiplanos se concentran en elevaciones superiores a 2.000 m, con pendientes bajas (media = $8,7^\circ$) y relieve relativo reducido (media = 78 m), en contraste con el terreno no-

altiplano (pendiente media = $20,4^\circ$, relieve medio = 166 m). Esto indica que las covariables topográficas por sí solas ya son informativas para la clasificación.

Sin embargo, al ajustar el modelo logístico base y examinar sus residuos, el índice de Moran I arrojó un valor de 0,610 ($p < 0,001$), confirmando una fuerte autocorrelación espacial positiva: los errores del modelo no se distribuyen aleatoriamente, sino que se agrupan geográficamente (Fig. 2). Los mapas LISA identificaron clusters significativos de residuos positivos (subestimación sistemática, en rojo) concentrados en las zonas de altiplano, mientras que los clusters de residuos negativos (sobrestimación, en azul) se localizan en los cañones y valles adyacentes (Fig. 3). Esta estructura espacial en los errores evidencia que el modelo no espacial falla al no incorporar la dependencia geográfica del fenómeno, y justifica la necesidad de los modelos espaciales.




Fig. 2. Diagrama de dispersión de Moran para los residuos del modelo logístico no espacial ($I = 0,610$, $p = 0,001$). La pendiente positiva confirma autocorrelación espacial.

Fuente: Elaboración propia.

3.2 Comparación de modelos pixel-enhanced

La Tabla 1 presenta los resultados de los 13 modelos evaluados a 50 m de resolución. Todos los modelos espaciales superan la línea base logística no espacial. El modelo Leroux-Pixel alcanza el mejor desempeño global, seguido por ICAR-Pixel y BYM-Pixel. Los tres modelos CAR ocupan las primeras posiciones del ranking, seguidos por los autorregresivos con rezago en la variable respuesta (SDM, SAR, GNS), y finalmente los modelos de error espacial (SEM, SDEM) y los que solo rezagan las covariables (SLX, OLS).




Fig. 3. Mapa LISA de residuos del modelo logístico no espacial. HH (rojo) = subestimación agrupada (zonas de altiplano); LL (azul) = sobreestimación agrupada (cañones y valles).

Fuente: Elaboración propia.

Tabla 1. Comparación de los 13 modelos evaluados a 50 m mediante pixel-enhancement. Ordenados por AUC descendente.

Modelo	AU C	Adj R ²	AIC	Accur acy	F1	Precis ion	Rec all
Leroux-Pixel	0,97 29	0,65 28	88,4 68	0,9382	0,79 06	0,810 7	0,77 16
ICAR-Pixel	0,96 83	0,62 49	95,5 74	0,9330	0,77 11	0,797 5	0,74 64
BYM-Pixel	0,96 81	0,62 37	95,8 72	0,9328	0,77 02	0,797 0	0,74 52
SDM-Pixel	0,96 26	0,60 00	101. 781	0,9253	0,73 91	0,785 7	0,69 77
SAR-Pixel	0,96 11	0,59 24	103. 711	0,9237	0,73 24	0,782 2	0,68 85
GNS-Pixel	0,96 03	0,58 92	104. 518	0,9254	0,73 78	0,790 2	0,69 19
SAC-Pixel	0,95 34	0,55 65	112. 859	0,9162	0,70 20	0,761 5	0,65 11
GLM(IN LA)- Pixel	0,95 31	0,55 46	113. 341	0,9161	0,70 44	0,756 7	0,65 89
SLX-Pixel	0,94 70	0,52 65	120. 484	0,9084	0,66 88	0,740 0	0,61 01
OLS-Pixel	0,94 66	0,52 45	120. 975	0,9081	0,66 75	0,739 3	0,60 85
SDM-Pixel	0,94 62	0,52 28	121. 424	0,9075	0,66 52	0,737 5	0,60 58
SEM-Pixel	0,94 55	0,51 93	122. 309	0,9067	0,66 17	0,735 4	0,60 14
Log. base	0,93 64	0,48 29	131. 732	0,8977	0,62 00	0,707 3	0,55 18

Fuente: Elaboración propia.

El ranking por Pseudo R² coincide exactamente con el de AUC, confirmando la consistencia de la evaluación. El Leroux-Pixel reduce el AIC en un 32,8% respecto al

logístico base (88.468 vs 131.732), indicando una mejora sustancial en la bondad de ajuste incluso después de penalizar por la complejidad adicional del modelo.




Fig. 4. Curvas ROC de los 5 mejores modelos pixel-enhanced comparados con el logístico base, evaluados sobre 24,8 millones de píxeles.

Fuente: Elaboración propia.

3.3 Efecto del pixel-enhancement

La Tabla 2 compara el desempeño de cada modelo areal cuando se aplica directamente sobre los píxeles (asignando a cada píxel la probabilidad de su celda de 5 km) frente al desempeño tras el pixel-enhancement. Todos los modelos mejoran sustancialmente al incorporar el detalle topográfico a 50 m.

Tabla 2. Comparación de AUC entre rasterización directa (5 km) y pixel-enhancement (50 m).

Modelo	AUC Directo (5km)	AUC Pixel (50m)	Mejora
Leroux	0,9400	0,9729	+0,0330
ICAR	0,9374	0,9683	+0,0309
BYM	0,9374	0,9681	+0,0307
SDM	0,9261	0,9626	+0,0365
SAR	0,9229	0,9611	+0,0382
GNS	0,8375	0,9603	+0,1228
SAC	0,9106	0,9534	+0,0428
GLM(INLA)	0,9072	0,9531	+0,0459
SLX	0,8919	0,9470	+0,0551
OLS	0,8906	0,9466	+0,0560
SDM	0,8898	0,9462	+0,0564
SEM	0,8857	0,9455	+0,0598

Fuente: Elaboración propia.




Fig. 5. Comparación de AUC entre rasterización directa (5 km) y pixel-enhancement (50 m) para los 12 modelos areales.

Fuente: Elaboración propia.

3.4 Ranking general incluyendo todas las familias

Al integrar los resultados de todas las familias de modelos, incluyendo GP y GWR evaluados en sus respectivas escalas (Tabla 3), se observa que los modelos GP de Clasificación y el Leroux-Pixel ocupan las dos primeras posiciones con desempeño prácticamente idéntico, seguidos por los demás modelos CAR y el modelo jerárquico con regiones.

Tabla 3. Ranking general de modelos por AUC, incluyendo todas las familias.

Modelo	AUC	Escala evaluación	Familia
GP Clasif.	0,9731	Malla 3 km	GP
Cov+Spatial		(test)	
Leroux-Pixel	0,9729	Ráster 50 m	CAR
ICAR-Pixel	0,9683	Ráster 50 m	CAR
BYM-Pixel	0,9681	Ráster 50 m	CAR




Fig. 6. Mapas de probabilidad de altiplano: observado (izquierda) y tres mejores modelos pixel-enhanced (Leroux, ICAR, BYM). Resolución 50 m.

Fuente: Elaboración propia.

4 Discusión

El resultado más destacado de este estudio es que todos los modelos que incorporan estructura espacial mejoran consistentemente la clasificación respecto al modelo logístico no espacial. El modelo base, que ignora la dependencia espacial, alcanza un AUC de 0,9364 — un valor ya alto, explicado por la fuerte correlación entre las variables topográficas y la presencia de altiplanos. Sin embargo, sus residuos muestran autocorrelación significativa (Moran I = 0,610), lo que revela que las covariables topográficas por sí solas no capturan toda la información relevante: existe un componente geográfico que el modelo base no puede ver.

Los modelos CAR (ICAR, BYM, Leroux) dominan el ranking porque su efecto aleatorio espacial ϕ captura precisamente esa variabilidad residual. Este efecto funciona como un "prior geográfico": asigna a cada celda un valor que depende de sus vecinos, de manera que zonas donde el modelo base subestima sistemáticamente reciben un ajuste positivo, y viceversa. El modelo Leroux se distingue porque incluye un parámetro de mezcla ρ que pondera entre un efecto completamente espacial (como ICAR) y uno independiente. En este caso $\rho \approx 0,99$, indicando que la variabilidad residual es casi enteramente espacial — es decir, los errores del modelo están

Jerárquico (Regiones)	0,9678	Ráster 50 m	Jerárquico
SDM-Pixel	0,9626	Ráster 50 m	Autorregresivo
GWR-Binomial	0,9620	Ráster 50 m	GWR
SAR-Pixel	0,9611	Ráster 50 m	Autorregresivo
Logístico no espacial	0,9522	Ráster 50 m	GLM
Logístico base (09b)	0,9364	Ráster 50 m	GLM

Fuente: Elaboración propia.

3.5 Mapas de predicción

La Fig. 6 muestra los mapas de probabilidad de altiplano generados por los tres mejores modelos pixel-enhanced, comparados con el mapa de referencia. Los modelos CAR (Leroux, ICAR, BYM) capturan con precisión los contornos de los altiplanos, con transiciones suaves en los bordes que reflejan la incertidumbre del modelo en las zonas de transición entre altiplano y laderas.

fuertemente agrupados geográficamente, no dispersos al azar. Esto le otorga al Leroux el menor AIC (88.468) y el mayor Pseudo R^2 (0,6528) entre todos los modelos.

Entre los modelos autorregresivos, los que incorporan rezago en la variable respuesta (SAR, SDM, GNS) superan a los que solo modelan correlación en los residuos (SEM, SDEM). Esto tiene una interpretación directa: la dependencia espacial en la clasificación de altiplanos opera fundamentalmente a través de la respuesta misma — si las celdas vecinas son altiplano, la celda central tiene mayor probabilidad de serlo también — más que a través de variables omitidas correlacionadas espacialmente.

La estrategia de pixel-enhancement demuestra ser efectiva para todos los modelos areales, con mejoras de AUC entre +0,03 (Leroux, que ya tenía el mejor efecto areal) y +0,12 (GNS, un modelo sobreparametrizado que por sí solo clasifica pobremente pero cuyo efecto espacial resulta informativo al combinarse con covariables a 50 m). Esta aproximación resuelve un problema práctico fundamental: los modelos areales capturan bien la estructura espacial a escala regional, pero su resolución de 5 km es inadecuada para cartografía de detalle. Al combinar ambas escalas se logra una predicción que conserva tanto la coherencia espacial como el detalle topográfico local.

Entre las limitaciones del estudio, cabe señalar que los modelos areales se evalúan in-sample sobre las 2.596 celdas de entrenamiento, mientras que los GP se evalúan sobre un conjunto de prueba independiente. Esto dificulta la comparación directa entre familias, aunque la similitud de AUC entre Leroux-Pixel (0,9729) y GP Clasificación (0,9731) sugiere un rendimiento comparable. Adicionalmente, el desbalance de clases (15,1% altiplano) afecta métricas como Precision y Recall: el mejor modelo (Leroux-Pixel) alcanza Precision = 0,8107 y Recall = 0,7716, indicando que aproximadamente un 23% de los altiplanos reales no son detectados con el umbral de 0,5, lo cual podría mejorarse ajustando el umbral de clasificación.

Estos resultados son coherentes con estudios previos que aplican modelos espaciales bayesianos a problemas de clasificación ambiental. El artículo de Cardona [11] encontró que los modelos INLA con BYM y heterogeneidad departamental ofrecieron el mejor ajuste para la distribución de Ochroma pyramidale en Colombia, corroborando la superioridad de los enfoques CAR bayesianos sobre la regresión logística clásica para datos con dependencia espacial.

5 Conclusiones

La incorporación de estructura espacial mejora significativamente la cartografía automática de altiplanos: el AUC pasa de 0,9364 (modelo logístico sin componente espacial) a 0,9729 (Leroux), y el Pseudo R² sube de 0,48 a 0,65. Los residuos autocorrelacionados del modelo base (Moran I = 0,610) confirman que la dependencia espacial es un componente que no puede ser ignorado en la clasificación de geoformas.

El modelo Leroux-Pixel, que combina un efecto aleatorio CAR bayesiano a escala de 5 km con covariables topográficas a 50 m, se posiciona como la mejor aproximación entre los modelos areales evaluados. Su rendimiento es prácticamente idéntico al de los Procesos Gaussianos (AUC = 0,9731), indicando que tanto los enfoques bayesianos areales como los basados en funciones continuas de correlación capturan de manera equivalente la estructura espacial de los altiplanos.

La estrategia de pixel-enhancement propuesta permite transferir predicciones de modelos areales (5 km) a resolución de detalle (50 m), con mejoras que van de +0,03 a +0,12 en AUC según el modelo. Esta técnica ofrece una vía práctica para aprovechar las ventajas de los modelos espaciales areales (interpretabilidad, eficiencia computacional, marco inferencial formal) sin sacrificar la resolución cartográfica necesaria para aplicaciones de planificación territorial.

Como perspectiva futura, se recomienda implementar esquemas de validación cruzada espacial (por bloques geográficos) para obtener estimaciones de desempeño libres de sesgo por autocorrelación, incorporar variables geológicas y climáticas como covariables adicionales, y extender el análisis a otras secciones de los Andes para evaluar la generalización de la metodología.

Referencias

[1] Flórez, A., Colombia: Evolución de sus relieves y modelados, Universidad Nacional de Colombia, Bogotá, 2003.

[2] Ideam, Ecosistemas continentales, costeros y marinos de Colombia, Instituto de Hidrología, Meteorología y Estudios Ambientales, Bogotá, 2007.

[3] Pike, R.J., Evans, I.S. and Hengl, T., Geomorphometry: a brief guide, in: Hengl, T. and Reuter, H.I. (Eds.), Geomorphometry: Concepts, Software, Applications, Developments in Soil Science, 33, pp. 3-30, 2009. DOI: [https://doi.org/10.1016/S0166-2481\(08\)00001-9](https://doi.org/10.1016/S0166-2481(08)00001-9)

[4] Tobler, W.R., A computer movie simulating urban growth in the Detroit region, Economic Geography, 46(sup1), pp. 234-240, 1970. DOI: <https://doi.org/10.2307/143141>

[5] Anselin, L., Spatial Econometrics: Methods and Models, Kluwer Academic Publishers, Dordrecht, 1988. DOI: <https://doi.org/10.1007/978-94-015-7799-1>

[6] Besag, J., York, J. and Mollié, A., Bayesian image restoration with two applications in spatial statistics, Annals of the Institute of Statistical Mathematics, 43(1), pp. 1-20, 1991. DOI: <https://doi.org/10.1007/BF00116466>

[7] Leroux, B.G., Lei, X. and Bheslow, N., Estimation of disease rates in small areas: a new mixed model for spatial dependence, in: Halloran, M.E. and Berry, D. (Eds.), Statistical Models in Epidemiology, the Environment and Clinical Trials, Springer, pp. 179-191, 2000. DOI: https://doi.org/10.1007/978-1-4612-1284-3_4

[8] Fotheringham, A.S., Yang, W. and Kang, W., Multiscale geographically weighted regression (MGWR), Annals of the American Association of Geographers, 107(6), pp. 1247-1265, 2017. DOI: <https://doi.org/10.1080/24694452.2017.1352480>

[9] Rasmussen, C.E. and Williams, C.K.I., Gaussian Processes for Machine Learning, MIT Press, Cambridge, MA, 2006.

[10] Gelman, A. and Hill, J., Data Analysis Using Regression and Multilevel/Hierarchical Models, Cambridge University Press, 2007. DOI: <https://doi.org/10.1017/CBO9780511790942>

[11] Cardona, V., Mapeando oportunidades: análisis geoespacial del balso en Colombia para la planificación forestal, Remote Sens., 17(x), 2025.

[12] Aristizábal, E., Libro Guía del curso Análisis Geoespacial, Universidad Nacional de Colombia, Departamento de Geociencias y Medio Ambiente, Facultad de Minas, 2024. Disponible en: https://edieraristizabal.github.io/Libro_AnalisisGeoespacial/

[13] Arias, L., Altiplanos y cañones en Antioquia: una mirada genética, Facultad de Ingeniería Universidad de Antioquia, (12-13), pp. 84-96, 1996.

[14] Büdel, J., Climatic Geomorphology, Princeton University Press, Princeton, 1982.

[15] Thomas, M.F., Geomorphology in the Tropics: A Study of Weathering and Denudation in Low Latitudes, John Wiley & Sons, Stirling, 1994.

[16] Ospina, D.R., Altiplanos de Colombia, Banco de Occidente, Bogotá, 2004.

[17] Bustos, X.M., Caracterización de superficies de erosión mediante geomorfología cuantitativa, Altiplano Antioqueño, Cordillera Central de Colombia, Terra Nueva Etapa, (46), pp. 43-67, 2013.

[18] Gallego, J.A., La geomorfología del oriente antioqueño: una combinación de procesos tectónicos de acumulación y modelado, XV Congreso Colombiano de Geología, Bucaramanga, 2015.

[19] Arias, L., El relieve de la zona central de Antioquia: Un palimpsesto de eventos tectónicos y climáticos, Facultad de Ingeniería Universidad de Antioquia, (10), pp. 9-24, 1995.